دانشگاه خوارزمی

پروژه کارشناسی (بهار ۱۴۰۴)

گزارش پروژه کارشناسی بیماری MS

ریحانه بنیادی

جناب آقای سعیدیان

دانشکده علوم ریاضی و کامپیوتر

دانشگاه خوارزمی

Contents

۱ مقدمه ۳

۲ داده‌های پروژه ۴

۳ تصاویر **MRI** با وزن **T1** و **FLAIR** ۴

۱.۳ تصاویر T1-weighted (T1) ۴

۲.۳ تصاویر FLAIR (Fluid-Attenuated Inversion Recovery) ۵

۴ هدف پروژه ۶

۵ مرحله اول: استخراج ناحیه مغز ۶

۶ مرحله دوم: تحلیل و استخراج ویژگی‌های پلاک‌ها ۷

۱.۶ تحلیل آماری و مکانی پلاک‌ها ۷

۲.۶ استخراج ویژگی‌های بافتی ۹

۷ مرحله سوم: تولید داده‌های ترکیبی ۱۰

۱.۷ تغییر موقعیت (*Translation*) ۱۰

۲.۷ تغییر مقیاس (*Scaling*) ۱۱

۳.۷ چرخش (*Rotation*): ۱۲

۴.۷ تغییر شکل (*Shapechanging*) ۱۳

۵.۷ ترکیب واقع‌گرایانه پلاک‌ها با تصاویر پس‌زمینه ۱۴

۸ تعیین مناطق مجاز برای قرارگیری پلاک‌ها با استفاده از ماسک مغز ۱۵

۹ **train** کردن مدل ۱۶

۱.۹ حذف داده‌های بدون پلاک ۱۶

۲.۹ پیدا کردن مدل مناسب ۱۶

۳.۹ انتخاب مدل U-net ۱۶

۴.۹ بررسی نتایج مدل ۱۷

۵.۹ بررسی نتایج تصویری ۲۰

۶.۹ نتایج مدل رو داده‌های تست ۲۱

۱۰ نتیجه‌گیری ۲۲

چکیده

این گزارش به تشریح یک پروژه تحقیقاتی با هدف بهبود عملکرد مدل‌های یادگیری عمیق در تشخیص پلاک‌های بیماری اماس (Multiple Sclerosis) در تصاویر MRI می‌پردازد. چالش اصلی در این زمینه، کمبود داده‌های برچسب‌خورده کافی برای آموزش مدل‌های دقیق است. به همین منظور، یک روش پیشرفته تولید داده ترکیبی (Data Augmentation) توسعه داده شده است که از پلاک‌های موجود، نمونه‌های جدیدی با شکل، اندازه و موقعیت متنوع ایجاد می‌کند. این روش شامل سه مرحله اصلی است: اول، تحلیل دقیق ویژگی‌های پلاک‌های موجود و استخراج ناحیه مغز؛ دوم، توسعه یک پایپ‌لاین تولید داده ترکیبی که از منحنی‌های بزیه (Bézier Curves) برای تغییر شکل پلاک‌ها و از نقشه‌های حرارتی برای قرارگیری واقع‌گرایانه آنها استفاده می‌کند؛ و سوم، آموزش و ارزیابی یک مدل U-Net برای نشان دادن افزایش دقت حاصل از استفاده از داده‌های تولیدشده. نتایج نشان می‌دهند که افزودن داده‌های ترکیبی به مجموعه داده اصلی، به طور چشمگیری عملکرد مدل را در شناسایی پلاک‌ها بهبود می‌بخشد.

۱ مقدمه

بیماری اماس (MS) یک بیماری خودایمنی است که بر سیستم عصبی مرکزی تأثیر می‌گذارد. تشخیص این بیماری اغلب بر اساس بررسی تصاویر MRI مغز، به ویژه نوع Flair و T1، توسط رادیولوژیست‌ها صورت می‌گیرد. با این حال، با توجه به حجم زیاد تصاویر و اندازه کوچک پلاک‌ها (ضایعات) در این تصاویر، تشخیص دقیق و سریع آنها چالش‌برانگیز است. امروزه، مدل‌های یادگیری عمیق به ابزاری قدرتمند برای بخش‌بندی (Segmentation) خودکار این پلاک‌ها تبدیل شده‌اند.

با وجود پتانسیل بالای این مدل‌ها، دستیابی به عملکرد مطلوب نیازمند مجموعه‌داده‌های بزرگ و برچسب‌خورده دقیق است. در تصاویر پزشکی، جمع‌آوری چنین داده‌هایی پرهزینه و زمان‌بر است و اغلب با محدودیت‌های اخلاقی همراه است. این کمبود داده، که به عنوان «مسئله حجم نمونه کوچک» شناخته می‌شود، باعث می‌شود مدل‌های آموزش‌دیده دچار بیش‌برازش (Overfitting) شده و در مواجهه با داده‌های جدید، عملکرد ضعیفی از خود نشان دهند. پروژه حاضر با هدف غلبه بر این چالش، به توسعه یک روش نوآورانه تولید داده ترکیبی می‌پردازد.

۲ داده‌های پروژه

تصاویر MRI ۲۵۰ بیمار جمع‌آوری شده است که هر کدام حدودا ۲۵ برش عمقی از مغزشان به نمایش گذاشته شده است. داخل برخی از این تصاویر پلاک‌هایی وجود دارد. تعدادی از این پلاک‌ها فعال (active) و تعدادی از آن‌ها غیرفعال (inactive) می‌باشند. پلاک‌های فعال عامل بیماری MS هستند و پلاک‌های غیرفعال خطری برای شخص ندارند.

۳ تصاویر MRI با وزن T1 و FLAIR

در تصویربرداری MRI، از سکانس‌های مختلفی برای ایجاد تصاویر با کنتراست‌های متفاوت از بافت‌های بدن استفاده می‌شود. در این جا، به توضیح دو نوع اصلی از این سکانس‌ها، تصاویر با وزن T1 و FLAIR، برای بررسی پلاک‌های ام‌اس می‌پردازیم.

۱.۳ تصاویر T1-weighted (T1)

تصاویر T1 معمولاً به عنوان تصاویر «آناتومیک» شناخته می‌شوند زیرا نمایی از مغز را ارائه می‌دهند که شباهت زیادی به ساختار واقعی آن دارد. این تصاویر با استفاده از زمان‌های تکرار (TR) و زمان‌های اکو (TE) کوتاه ایجاد می‌شوند که باعث می‌شود بافت‌هایی با زمان آسایش T1 کوتاه، روشن‌تر دیده شوند.

- کنتراست اصلی: در تصاویر T1، چربی (Fat) به رنگ روشن (سفید) و مایعات (مانند مایع مغزی‌ـنخاعی یا CSF) به رنگ تیره (سیاه) دیده می‌شوند.
- تزریق: بعد از تزریق گادولینیوم، پلاک‌های غیرفعال در تصاویر دیده نمی‌شوند و پلاک‌های فعال به شکل سفید و واضح درمی‌آیند.
- ظاهر بافت‌های مغزی: ماده سفید معمولاً از ماده خاکستری روشن‌تر است.
- کاربرد بالینی: این سکانس برای بررسی دقیق آناتومی مغز، تشخیص تومورها و ضایعاتی که با ماده کنتراست (مانند گادولینیوم) فعال می‌شوند، بسیار مفید است.

۲.۳ تصاویر FLAIR (Fluid-Attenuated Inversion Recovery)

سکانس FLAIR یک تکنیک تخصصی MRI است که به ویژه برای شناسایی ناهنجاری‌ها در مغز و نخاع کاربرد دارد. ویژگی کلیدی این سکانس، توانایی آن در حذف سیگنال مایعات است. این امر با استفاده از یک پالس اینورژن و زمان‌های TR و TE طولانی، سیگنال مایع مغزی‌ـنخاعی را سرکوب می‌کند.

- کنتراست اصلی: برخلاف تصاویر T2 که در آن مایعات روشن هستند، در تصاویر FLAIR مایع مغزی‌ـنخاعی به رنگ تیره در می‌آید. این ویژگی به تمایز بهتر بین ضایعات و مایعات اطراف کمک می‌کند.
- ظاهر بافت‌های مغزی: پلاک‌های اماس و مناطق ملتهب به دلیل محتوای آب بالا، به شدت روشن (Hyperintense) دیده می‌شوند که در مقایسه با پس‌زمینه تیره مایع مغزی‌ـنخاعی به راحتی قابل تشخیص هستند.
- کاربرد بالینی: این سکانس به دلیل حساسیت بالا به ضایعات ماده سفید، ابزاری اصلی در تشخیص و پایش بیماری اماس است.
- داده‌های این پروژه از نوع FLAIR هستند.

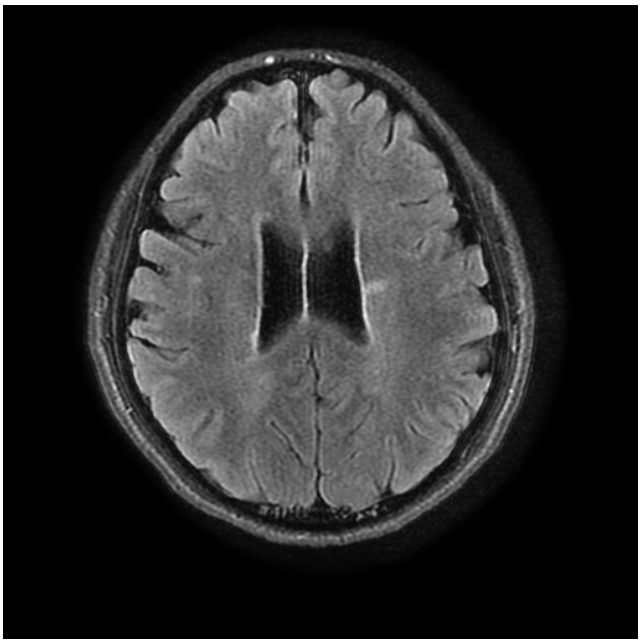


Figure ۱: نمونه‌ای از داده‌های FLAIR

۴ هدف پروژه

هدف نهایی این پروژه استفاده از هوش مصنوعی جهت حذف تزریق گادولینیوم به مغز، به علت عوارض زیاد کوتاه و بلندمدت برای بیمار، و همچنین هزینه زیاد این تزریق برای بیمار و بیمارستان است. این پروژه ۴ فاز دارد که در این گزارش به فاز ۴م آن پرداخته می‌شود.

۵ مرحله اول: استخراج ناحیه مغز

پیش از هرگونه پردازش بر روی پلاک‌ها، لازم است تا ناحیه اصلی مغز از سایر بافت‌ها و نواحی اطراف مانند جمجمه، پوست سر و چشم‌ها جدا شود. این فرآیند که به عنوان استخراج مغز (Brain Extraction) یا ماسک‌گذاری مغز (Brain Masking) شناخته می‌شود، دقت مراحل بعدی را به شدت افزایش می‌دهد. برای این منظور، یک رویکرد چندمرحله‌ای به کار گرفته شد:

۱. ماسک‌گذاری اولیه با آستانه‌گذاری: در ابتدا، با استفاده از یک تکنیک ساده آستانه‌گذاری (threshold)، یک ماسک اولیه از ناحیه مغز ایجاد شد. این روش سریع است، اما دقت پایینی دارد و اغلب شامل نواحی غیرمغزی یا بخش‌هایی از مغز که به اشتباه حذف شده‌اند، می‌شود.

۲. اصلاح دستی با رابط کاربری گرافیکی (**GUI**): برای رفع نواقص ماسک‌های اولیه، یک رابط کاربری گرافیکی ساده طراحی شد تا امکان اصلاح دستی و دقیق مرزهای ماسک فراهم شود.

۳. آموزش مدل U-Net اولیه: ماسک‌های اصلاح‌شده به عنوان داده آموزش برای یک مدل شبکه عصبی U-Net مورد استفاده قرار گرفتند. این مدل با هدف یادگیری خودکار مرزهای مغز، آموزش دید.

۴. اصلاح و آموزش مجدد: پس از آموزش اولیه، خروجی مدل U-Net مجدداً با استفاده از رابط کاربری گرافیکی اصلاح شد. این مرحله چرخه‌ای از بهبود را ایجاد کرد که منجر به تولید یک مدل U-Net نهایی با دقت بالا در استخراج ناحیه مغز شد.



Figure ۲: نمونه‌ای از ماسک تولید شده توسط مدل U-net

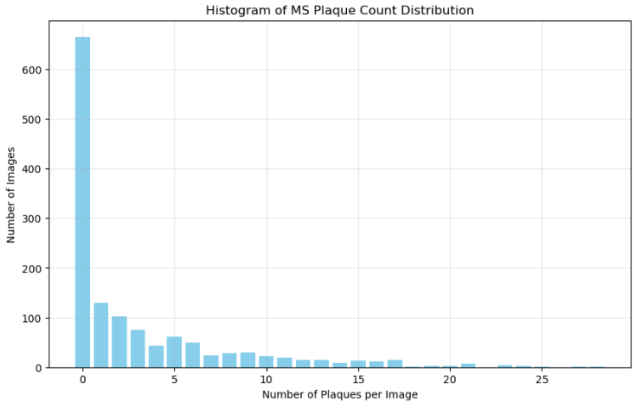
۶ مرحله دوم: تحلیل و استخراج ویژگی‌های پلاک‌ها

این مرحله از پروژه، به تحلیل دقیق و سیستماتیک داده‌های موجود می‌پردازد. هدف، استخراج ویژگی‌های کلیدی از پلاک‌های بیماری ام‌اس است تا به درکی عمیق‌تر از مشخصات آن‌ها دست یابیم. این دانش، مبنای اصلی برای تولید داده‌های مصنوعی واقع‌گرایانه در مراحل بعدی خواهد بود. این تحلیل شامل سه بخش اصلی است: تحلیل آماری، تحلیل مکانی و استخراج ویژگی‌های بافتی.

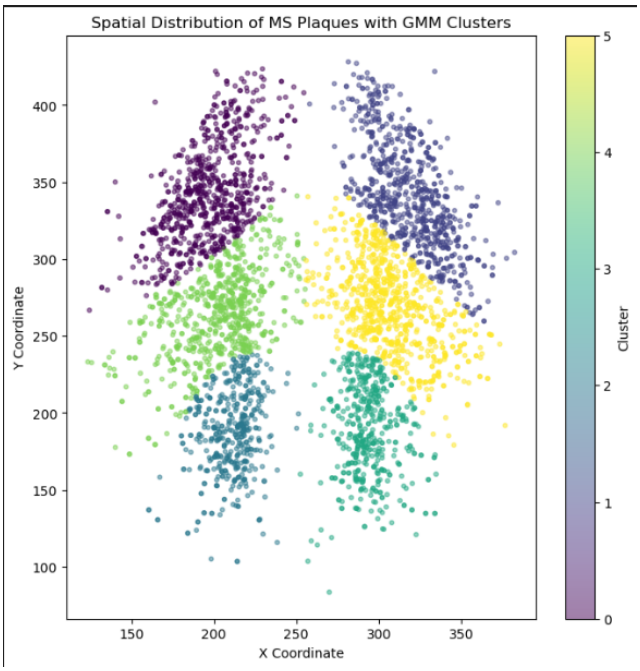
۱.۶ تحلیل آماری و مکانی پلاک‌ها

در این بخش، از ماسک‌های پلاک برای استخراج داده‌های کمی و مکانی استفاده شد.

- توزیع تعداد پلاک‌ها: با شمارش تعداد پلاک‌ها در هر تصویر، یک تحلیل آماری دقیق انجام شد. میانگین تعداد پلاک در هر تصویر ۲.۹۹ با انحراف معیار ۴.۷۳ به دست آمد. ضریب چولگی (Skewness) مثبت ۲.۰۶ نشان‌دهنده توزیع نامتقارن است؛ به این معنی که اکثر تصاویر تعداد پلاک کمی دارند، در حالی که تعداد محدودی از آن‌ها پلاک‌های زیادی را در بر می‌گیرند.



- توزیع مکانی: برای درک الگوی قرارگیری پلاک‌ها، از مختصات مرکز ثقل (Centroid) هر پلاک استفاده شد. برای شناسایی خوشه‌ها (Clusters) پلاک، مدل مخلوط گوسی (Gaussian Mixture Model) با ۶ جزء به کار گرفته شد. این تحلیل به ما امکان می‌دهد تا مناطق خاصی از مغز که پلاک‌ها در آن‌ها شیوع بیشتری دارند را شناسایی کنیم. در نهایت، یک نقشه حرارتی (Heatmap) به صورت هیستوگرام دوبعدی از توزیع پلاک‌ها ساخته شد که توصیف بصری دقیقی از مکان‌های تجمع پلاک‌ها را ارائه می‌دهد.



۲.۶ استخراج ویژگی‌های بافتی

برای درک بهتر بافت داخلی پلاک‌ها و تمایز آن‌ها از بافت‌های مغزی، ویژگی‌های مختلفی از پیکسل‌های درون هر پلاک استخراج شد.

- روشنایی (**Intensity**): میانگین و انحراف معیار روشنایی هر پلاک به عنوان معیارهای پایه اندازه‌گیری شدند. همچنین، چولگی (Skewness) روشنایی نیز برای هر پلاک محاسبه شد.
- ویژگی‌های بافت **GLCM**: برای بررسی جزئیات بافتی پلاک‌ها، ماتریس هم‌وقوعی سطح خاکستری (Gray-Level Co-occurrence Matrix) به کار گرفته شد. از این روش چهار ویژگی کلیدی استخراج گردید:

۱. کنتراست (**Contrast**): معیاری از تفاوت‌های موضعی در روشنایی، که نشان‌دهنده وضوح لبه‌های پلاک است.

۲. همگنی (**Homogeneity**): میزان یکنواختی بافت پلاک را نشان می‌دهد، با مقادیر بالاتر که به بافت‌های یکنواخت‌تر اشاره دارد.

۳. انرژی (**Energy**): نشان‌دهنده فشردگی و یکنواختی بافت، که مقادیر بالاتر آن به بافت‌های فشرده‌تر و یکنواخت‌تر اشاره دارد.

۴. همبستگی (**Correlation**): درجه همبستگی خطی پیکسل‌ها را نشان می‌دهد.

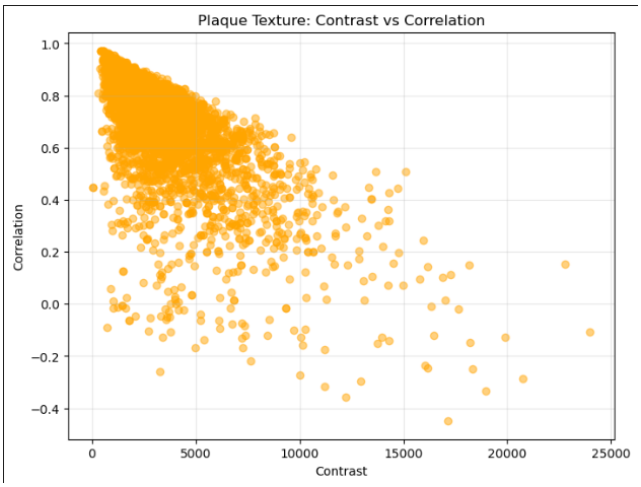


Figure ۳: همبستگی

۷ مرحله سوم: تولید داده‌های ترکیبی

این مرحله از پروژه، راهکار اصلی برای غلبه بر چالش کمبود داده است. در این بخش، پلاک‌های استخراج‌شده از تصاویر اصلی به عنوان مواد اولیه برای تولید مجموعه‌ای بزرگ و متنوع از نمونه‌های مصنوعی استفاده می‌شوند. فرآیند تولید داده ترکیبی در چند گام کلیدی و با دقت بالا انجام می‌گیرد که هر یک به افزایش واقع‌گرایی تصاویر مصنوعی کمک می‌کنند.

۱.۷ تغییر موقعیت (*Translation*)

تغییر موقعیت پلاک‌ها فراتر از قرار دادن تصادفی آن‌ها در یک تصویر است. هدف، قرار دادن هر پلاک مصنوعی در مکانی است که از نظر آماری و بصری منطقی به نظر برسد. برای دستیابی به این هدف، یک رویکرد مبتنی بر احتمال به کار گرفته شد که شامل مراحل زیر است:

- تولید نقشه حرارتی (**Heatmap**): نقشه حرارتی، یک توزیع احتمال از محل‌های قرارگیری پلاک‌ها در مغز را نشان می‌دهد. این نقشه با استفاده از مختصات مرکز ثقل (Centroid) تمام پلاک‌های اصلی تولید می‌شود. سپس، با اعمال یک فیلتر گوسی (Gaussian Filter) با انحراف معیار بالا ($\text{sigma} = 20.0$)، این توزیع به یک نقشه پیوسته و نرم تبدیل می‌گردد که مناطق با شیوع بالای پلاک را برجسته می‌کند.
- تولید نقشه بافت (**Texture Map**): پلاک‌های فعال اغلب در مناطق هموار و یکنواخت ماده سفید مغز ظاهر می‌شوند. برای شبیه‌سازی این الگو، با استفاده از فیلتر سوبل (Sobel Filter)، یک نقشه بافت از گرادیان تصویر مقصد (تصویری که پلاک روی آن قرار می‌گیرد) ایجاد می‌شود. این نقشه، مناطقی با لبه‌های تیز و بافت‌های پرجزئیات را جریمه می‌کند و به مناطق هموار وزن بیشتری می‌دهد.
- نقشه احتمال ترکیبی: در نهایت، نقشه حرارتی (بر اساس الگوی مکانی) و نقشه بافت (بر اساس الگوی بصری) با یکدیگر ترکیب می‌شوند. این ترکیب، یک نقشه احتمال نهایی به دست می‌دهد که هر نقطه را بر اساس منطقی بودن مکان و مناسب بودن بافت پس‌زمینه برای قرارگیری پلاک، امتیازدهی می‌کند.

محل قرارگیری پلاک‌های جدید به صورت تصادفی از این نقشه احتمال ترکیبی نمونه‌برداری می‌شود. این رویکرد تضمین می‌کند که پلاک‌ها در مناطقی قرار داده شوند که هم از نظر آماری با پلاک‌های واقعی هم‌خوانی داشته باشند و هم از نظر بصری به طور طبیعی با تصویر پس‌زمینه ترکیب شون

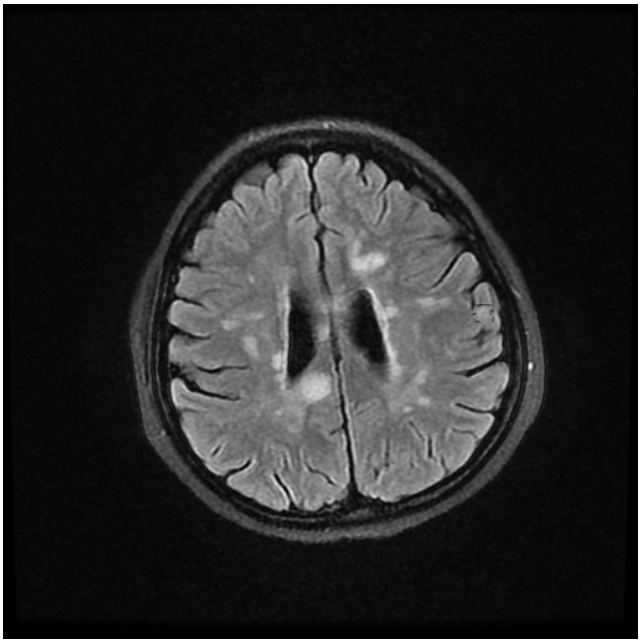


Figure ۴: داده جدید تولید شده بر اساس translation

۲.۷ تغییر مقیاس (*Scaling*)

مقیاس‌گذاری یک عملیات حیاتی برای ایجاد پلاک‌هایی با اندازه‌های متفاوت است و به مدل کمک می‌کند تا نسبت به تغییرات اندازه در تصاویر واقعی، مقاوم باشد.

- انتخاب ضریب مقیاس تصادفی: برای هر پلاک، یک ضریب مقیاس (Scale Factor) تصادفی در بازه (۰.۷، ۱.۵) انتخاب می‌شود. این بازه گسترده، تنوع زیادی در اندازه پلاک‌ها ایجاد می‌کند، از پلاک‌های کوچک‌تر از نمونه‌های اصلی تا پلاک‌های بزرگ‌تر.

- وزن دهی و انتخاب تصاویر مقصد: برای هر تصویر مقصد، تعداد پلاک‌های فعلی محاسبه می‌شود. سپس با استافاده از گرادیان و نرمال‌سازی نواحی صاف و روشن که مقاصد مناسبی هستند انتخاب می‌شوند. تصاویر با پلاک‌های کمتر و وزن روشنایی بالاتر با احتمال بیشتر برای جایگذاری انتخاب می‌شوند.

این فرآیند تضمین می‌کند که پلاک‌های مصنوعی با اندازه‌های مختلفی تولید شوند، که این تنوع برای آموزش یک مدل دقیق، که بتواند پلاک‌ها را صرف‌نظر از اندازه آن‌ها شناسایی کند، ضروری است.

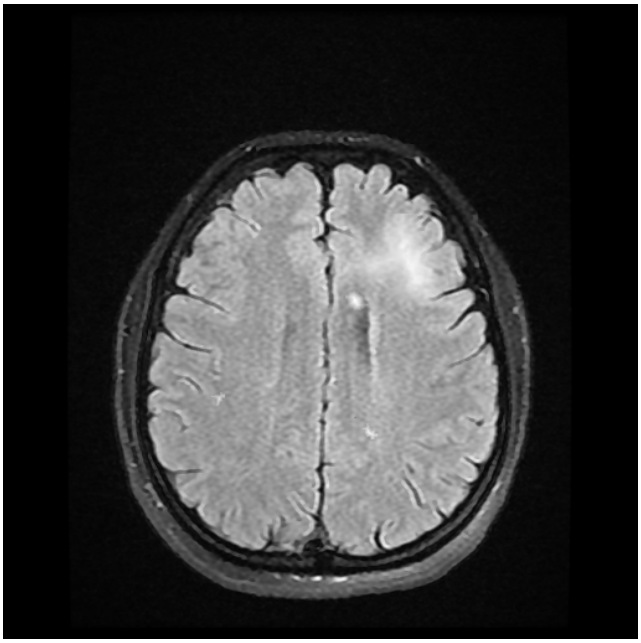


Figure ۵: داده جدید تولید شده بر اساس scaling

۳.۷ چرخش (*Rotation*):

چرخش پلاک‌ها یک عملیات کلیدی برای شبیه‌سازی جهت‌گیری‌های مختلف پلاک‌ها در مغز است. این کار باعث می‌شود مدل یادگیری عمیق نسبت به تغییرات زاویه‌ای در پلاک‌های واقعی، مقاوم‌تر و دقیق‌تر عمل کند. فرآیند چرخش بر اساس الگوریتم زیر اجرا می‌گردد:

- انتخاب زاویه چرخش تصادفی: برای هر پلاک، یک زاویه چرخش تصادفی در بازه [°45−، °45] انتخاب می‌شود. این بازه، جهت‌گیری‌های متنوعی را پوشش می‌دهد که در تصاویر واقعی MRI مشاهده می‌شود.

- تولید ماتریس چرخش: با استفاده از توابع کتابخانه OpenCV، یک ماتریس چرخش حول مرکز پلاک ایجاد می‌گردد. این ماتریس شامل اطلاعات مربوط به زاویه چرخش و مرکز آن است.

این فرآیند تضمین می‌کند که پلاک‌های مصنوعی با جهت‌گیری‌های متفاوتی تولید شوند، که این تنوع برای آموزش یک مدل دقیق، که بتواند پلاک‌ها را صرف‌نظر از جهت‌گیری آن‌ها شناسایی کند، ضروری است.

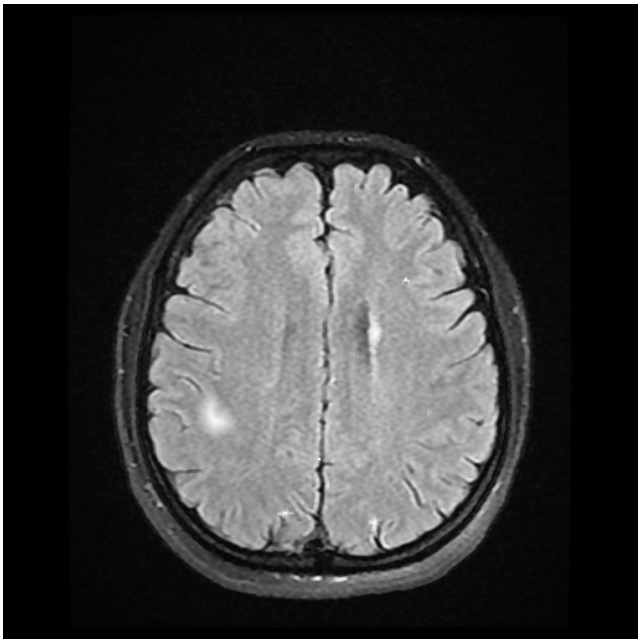


Figure ۶: داده جدید تولید شده بر اساس rotation

۴.۷ تغییر شکل (*Shapechanging*)

برای ایجاد پلاک‌هایی با اشکال غیریکنواخت و ارگانیک، از یک روش تغییر شکل شعاعی مبتنی بر منحنی‌های بزیه (Bezier Curves) استفاده شد. این فرآیند از طریق دستکاری دقیق مرزهای پلاک‌ها، تنوع هندسی لازم برای آموزش مدل را فراهم می‌کند.

- محاسبه پروفایل شعاعی: ابتدا، مرکز ثقل (Centroid) هر پلاک محاسبه شده و یک پروفایل شعاعی از مرز آن به دست می‌آید. این پروفایل، شعاع پلاک را به ازای $360°$ زاویه حول مرکز ثقل مشخص می‌کند. این گام، شکل هندسی اولیه پلاک را به یک داده قابل پردازش تبدیل می‌کند.
- دستکاری با منحنی بزیه: این پروفایل شعاعی توسط چند نقطه کنترلی (Anchors) در امتداد یک منحنی بزیه دستکاری می‌شود. این دستکاری تصادفی با پارامتری به نام shape factor کنترل می‌گردد که میزان تغییر شکل را تعیین می‌کند و منجر به ایجاد تنوع هندسی در پلاک‌ها می‌شود.

این فرآیند تضمین می‌کند که پلاک‌های مصنوعی، اشکالی متنوع و واقعی داشته باشند و از حالت‌های بیضی‌گون و تکراری نمونه‌های اصلی خارج شوند.

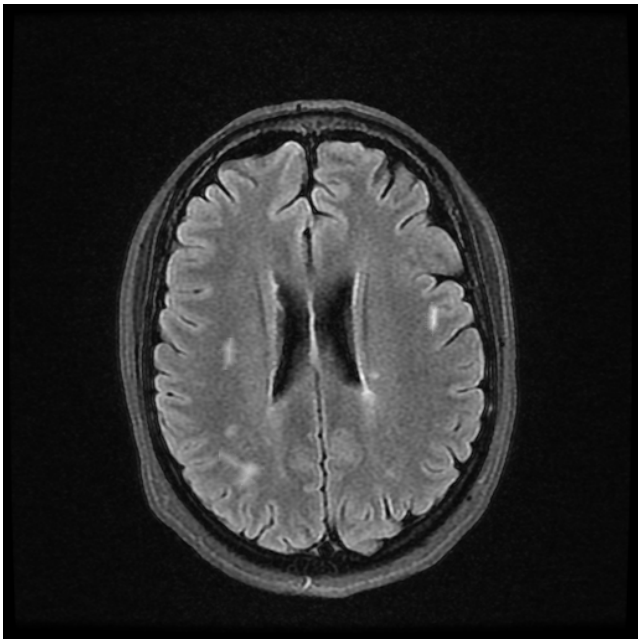


Figure ۷: داده جدید تولید شده بر اساس shape changing

۵.۷ ترکیب واقع‌گرایانه پلاک‌ها با تصاویر پس‌زمینه

پس از تغییرات هندسی، مهم‌ترین گام، ترکیب پلاک‌های مصنوعی با تصاویر MRI پس‌زمینه به شکلی است که کاملاً طبیعی و غیرقابل‌تشخیص به نظر برسند. در حالی که تکنیک‌های پیشرفته‌ای مانند Poisson Blending برای این منظور وجود دارند، رویکرد پروژه ما با استفاده از ترکیبی از روش‌های بهینه و مؤثر، به نتیجه‌ای مشابه و با کارایی بالاتر دست یافته است. این فرآیند با دقت و جزئیات فراوان، پلاک‌ها را با بافت مغزی ادغام می‌کند:

- تولید ماسک با مرز نرم (*Mask Feathered*): برای جلوگیری از ایجاد مرزهای تیز و مصنوعی، یک ماسک با مرز نرم برای هر پلاک ساخته می‌شود. این ماسک، که با استفاده از یک فیلتر گوسی (Gaussian Filter) با مقدار sigma مشخص (3.0) تولید می‌شود، دارای یک گرادیان شفافیت است. این گرادیان از بالاترین مقدار (در مرکز پلاک) به صفر (در لبه‌های پلاک) کاهش می‌یابد. در نهایت، با استفاده از این ماسک، پلاک به صورت هموار و تدریجی با بافت اطراف خود ترکیب می‌شود.

- تطبیق هیستوگرام (*Matching Histogram*): یکی از دلایل اصلی غیرطبیعی به نظر رسیدن تصاویر ترکیبی، تفاوت در روشنایی و کنتراست پلاک با ناحیه پس‌زمینه است. برای حل این مشکل، هیستوگرام روشنایی پلاک

مصنوعی با هیستوگرام ناحیه مغز در محل قرارگیری آن تطبیق داده می‌شود. این فرآیند، توزیع رنگی پلاک را به گونه‌ای تغییر می‌دهد که با محیط جدید خود همخوانی داشته باشد و از نظر بصری یکپارچگی لازم را کسب کند.

- ترکیب نهایی (*Blending Final*): پس از آماده‌سازی پلاک و ماسک، ترکیب نهایی با استفاده از یک فرمول ترکیبی خطی (Linear Blending) انجام می‌شود. این فرمول به شکل

$$I_{\text{new}} = \alpha \times I_{\text{plaque}} + (1 - \alpha) \times I_{\text{background}}$$

است که در آن، I_{new} تصویر جدید، I_{plaque} پلاک آماده‌سازی‌شده، $I_{\text{background}}$ ناحیه پس‌زمینه و α مقادیر ماسک نرم هستند. این روش، پلاک را به صورت طبیعی در تصویر ادغام می‌کند.

علاوه بر این تکنیک‌ها، برای افزایش هر چه بیشتر واقع‌گرایی، از تغییرات دیگری مانند تغییر شکل الاستیک (*Elastic Deformation*) برای ایجاد اشکال ارگانیک‌تر در پلاک و ماسک، و عملیات‌های مورفولوژیکی تصادفی (*Random Morphological Operations*) برای جلوگیری از شکل‌های هندسی کامل استفاده می‌شود. این اقدامات ترکیبی، تضمین می‌کنند که تصاویر مصنوعی به دست‌آمده از نظر کیفیت و تنوع، قابل مقایسه با داده‌های واقعی باشند و به بهبود عملکرد مدل در تشخیص پلاک‌ها کمک کنند.

۸ تعیین مناطق مجاز برای قرارگیری پلاک‌ها با استفاده از ماسک مغز

برای اطمینان از اینکه پلاک‌های مصنوعی به صورت طبیعی و در بافت مغز قرار می‌گیرند، نه در خارج از آن، از ماسک‌های مغز استفاده شد. این ماسک‌ها به عنوان یک راهنمای دقیق برای تعیین مناطق مجاز (Allowed Region) عمل می‌کنند.

- استخراج ماسک مغز: در مرحله اول پروژه، ماسک‌های مغز از تصاویر MRI استخراج شدند. این ماسک‌ها، ناحیه مغز را از سایر بافت‌ها مانند جمجمه و فضای خالی جدا می‌کنند.
- ترکیب با نقشه احتمال: در مرحله تولید داده، ماسک مغز به صورت یک فیلتر باینری (Binary Filter) عمل می‌کند. این فیلتر، با نقشه احتمال ترکیبی (که از ترکیب نقشه حرارتی و نقشه بافت به دست آمده بود) ترکیب می‌شود.

- اعمال محدودیت: در فرآیند نمونه‌برداری تصادفی برای تعیین محل قرارگیری پلاک، تنها مختصاتی که درون ماسک مغز قرار دارند و دارای وزن احتمالی مثبت هستند، انتخاب می‌شوند. این محدودیت تضمین می‌کند که پلاک‌های جدید به طور انحصاری در داخل بافت مغز جایگذاری شوند.

علاوه بر این، در فرآیند جایگذاری پلاک، یک بررسی اضافی (Overlap Check) نیز انجام می‌شود تا از تداخل بیش از حد پلاک‌های مصنوعی با پلاک‌های از پیش موجود در تصویر مقصد جلوگیری شود. این تدابیر ترکیبی، امکان تولید تصاویری را فراهم می‌سازد که نه تنها از نظر بصری واقع‌گرایانه هستند، بلکه از نظر پزشکی نیز معتبر (Medically Valid) محسوب می‌شوند.

۹ train کردن مدل

در این قسمت ما ابتدا به دنبال مدلی هستیم که پلاک‌ها را از بافت مغزی جدا کند و تشخیص دهد.

۱.۹ حذف داده‌های بدون پلاک

جهت آموزش مدل، برای بهتر کردن دقت مدل و جلوگیری از overfit عکس‌هایی که ماسک متناظرشان هیچ پلاکی ندارد را همراه با ماسک متناظر، حذف می‌کنیم. این عمل باعث کاهش داده از ۱۳۵۰ به ۶۵۸ شد که البته در توزیع عددی که پیش‌تر دیدیم هم مشخص بود.

۲.۹ پیدا کردن مدل مناسب

در این مرحله مدل‌های مختلفی همچون DeepLabv3Plus-Resnet50 و PSPNet امتحان شدند که با overfitting و یا خطاهایی در راستای هزینه محاسباتیی بالا مواجه شدند.

۳.۹ انتخاب مدل U-net

در نهایت مدل U-net با معماری که در تصویر مشاهده می‌کنید، انتخاب شد. این مدل برای مارهای پزشکی مانند segmentation که هدف پروژه ما می‌باشد، مناسب است.

- تقسیم‌بندی داده‌ها: داده‌های اصلی و داده‌های ترکیبی تولید شده به سه مجموعه تقسیم شدند:

۱. داده‌های آموزش (**train data**) شامل ۵۸۵ نمونه، برای آموزش مدل.

۲. داده‌های اعتبارسنجی (**validation data**) شامل ۱۰۰ نمونه، برای نظارت بر عملکرد مدل در حین آموزش و جلوگیری از بیش‌برازش (Overfitting).

۳. داده‌های تست (**test data**) شامل ۵۳ نمونه، برای ارزیابی نهایی عملکرد مدل.

- مدل **U-Net**: یک مدل U-Net با معماری متداول برای وظیفه بخش‌بندی تصاویر انتخاب شد. این مدل با لایه‌های انکودر–دیکودر خود، قادر است ویژگی‌های مکانی پلاک‌ها را در اندازه‌های مختلف دریافت کرده و ماسک نهایی را با دقت بالا تولید کند.
- تنظیمات آموزش: برای آموزش مدل، از تابع زیان Dice Loss به عنوان معیاری برای سنجش همپوشانی بین ماسک‌های پیش‌بینی شده و ماسک‌های واقعی استفاده شد. این انتخاب به دلیل ماهیت نامتعادل داده‌ها (کم بودن تعداد پیکسل‌های پلاک نسبت به پیکسل‌های پس‌زمینه) انجام شده است. همچنین، بهینه‌ساز (Optimizer) Adam برای به‌روزرسانی وزن‌ها به کار گرفته شد.

۴.۹ بررسی نتایج مدل

این مدل با ۳۰ epoch آموزش داده شد و در ادامه بر اساس معیارهای مختلف، کیفیت این مدل را ارزیابی می‌کنیم.

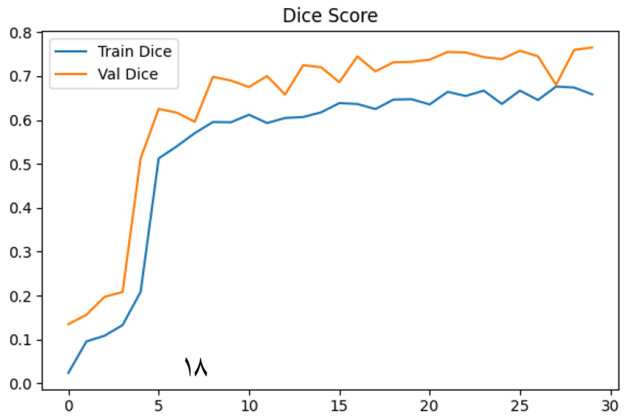
- ضریب دایس **Coefficient Dice** ضریب دایس یک معیار آماری برای سنجش شباهت فضایی بین دو مجموعه داده است. در زمینه بخش‌بندی تصویر، این معیار همپوشانی ماسک پیش‌بینی شده توسط مدل (P) و ماسک واقعی (G) را اندازه‌گیری می‌کند. فرمول آن به صورت زیر است:

$$Dice(P, G) = \frac{2|P \cap G|}{|P| + |G|}$$

مقدار این ضریب بین ۰ (بدون همپوشانی) و ۱ (همپوشانی کامل) متغیر است. در این پروژه، مدل به ضریب دایس ۷۴ درصد در مجموعه داده اعتبارسنجی دست یافت که نشان‌دهنده همپوشانی بالا و عملکرد بسیار خوب مدل در شناسایی پلاک‌ها است. این نتیجه نشان می‌دهد که مدل، بخش بزرگی از پلاک‌های واقعی را به درستی شناسایی کرده و مرزهای آن‌ها را با دقت قابل قبولی تخمین زده است.

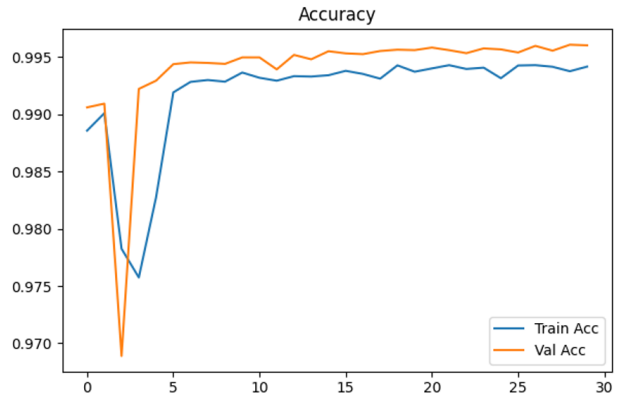
Layer (type)	Output Shape	Param #	Connected to
input_layer_1 (InputLayer)	(None, 352, 352, 3)	0	-
conv2d_15 (Conv2D)	(None, 352, 352, 32)	896	input_layer_1[0]…
conv2d_16 (Conv2D)	(None, 352, 352, 32)	9,248	conv2d_15[0][0]
max_pooling2d_3 (MaxPooling2D)	(None, 176, 176, 32)	0	conv2d_16[0][0]
conv2d_17 (Conv2D)	(None, 176, 176, 64)	18,496	max_pooling2d_3[…
conv2d_18 (Conv2D)	(None, 176, 176, 64)	36,928	conv2d_17[0][0]
max_pooling2d_4 (MaxPooling2D)	(None, 88, 88, 64)	0	conv2d_18[0][0]
conv2d_19 (Conv2D)	(None, 88, 88, 128)	73,856	max_pooling2d_4[…
conv2d_20 (Conv2D)	(None, 88, 88, 128)	147,584	conv2d_19[0][0]
max_pooling2d_5 (MaxPooling2D)	(None, 44, 44, 128)	0	conv2d_20[0][0]
conv2d_21 (Conv2D)	(None, 44, 44, 256)	295,168	max_pooling2d_5[…
conv2d_22 (Conv2D)	(None, 44, 44, 256)	590,080	conv2d_21[0][0]
dropout (Dropout)	(None, 44, 44, 256)	0	conv2d_22[0][0]
up_sampling2d_3 (UpSampling2D)	(None, 88, 88, 256)	0	dropout[0][0]
concatenate_3 (Concatenate)	(None, 88, 88, 384)	0	up_sampling2d_3[… conv2d_20[0][0]
conv2d_23 (Conv2D)	(None, 88, 88, 128)	442,496	concatenate_3[0]…
conv2d_24 (Conv2D)	(None, 88, 88, 128)	147,584	conv2d_23[0][0]
dropout_1 (Dropout)	(None, 88, 88, 128)	0	conv2d_24[0][0]
up_sampling2d_4 (UpSampling2D)	(None, 176, 176, 128)	0	dropout_1[0][0]
concatenate_4 (Concatenate)	(None, 176, 176, 192)	0	up_sampling2d_4[… conv2d_18[0][0]
conv2d_25 (Conv2D)	(None, 176, 176, 64)	110,656	concatenate_4[0]…
conv2d_26 (Conv2D)	(None, 176, 176, 64)	36,928	conv2d_25[0][0]
up_sampling2d_5 (UpSampling2D)	(None, 352, 352, 64)	0	conv2d_26[0][0]
concatenate_5 (Concatenate)	(None, 352, 352, 96)	0	up_sampling2d_5[… conv2d_16[0][0]
conv2d_27 (Conv2D)	(None, 352, 352, 32)	27,680	concatenate_5[0]…
conv2d_28 (Conv2D)	(None, 352, 352, 32)	9,248	conv2d_27[0][0]
conv2d_29 (Conv2D)	(None, 352, 352, 1)	33	conv2d_28[0][0]

Figure ۸: معماری مدل U-net

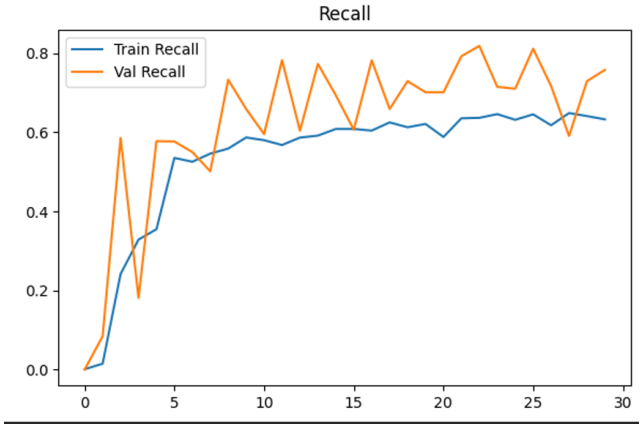


- دقت **accuracy** دقت یک معیار کلی است که نسبت تعداد پیکسل‌های به درستی طبقه‌بندی شده (پیکسل‌های پلاک که به درستی پلاک تشخیص داده شده و پیکسل‌های پس‌زمینه که به درستی پس‌زمینه تشخیص داده شده) به کل پیکسل‌ها را نشان می‌دهد. نتایج نشان می‌دهد که مدل به دقت ۹۹ درصد در مجموعه داده اعتبارسنجی دست یافته است.

این مقدار بسیار بالا به دلیل ماهیت نامتعادل داده‌ها (کم بودن تعداد پیکسل‌های پلاک نسبت به پس‌زمینه) قابل انتظار است، اما همچنان نشان‌دهنده عملکرد قوی مدل در طبقه‌بندی پیکسل‌های پس‌زمینه است.

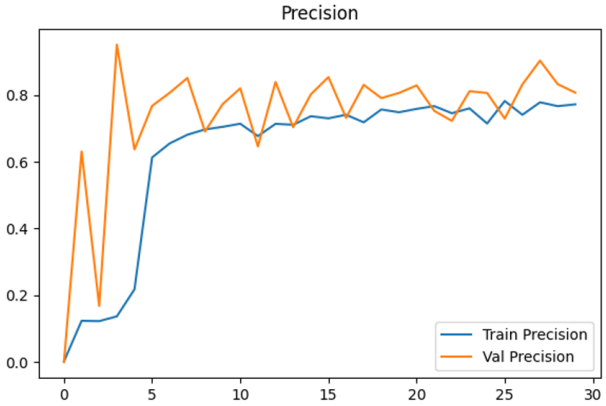


- حساسیت **recall** یادآوری (یا حساسیت) توانایی مدل را در شناسایی تمامی پلاک‌های واقعی (پیکسل‌های مثبت واقعی) اندازه‌گیری می‌کند. این معیار به ویژه در تشخیص پزشکی که از دست دادن یک پلاک می‌تواند منجر به تشخیص نادرست شود، اهمیت فراوانی دارد. مدل به یادآوری ۶۹ درصد دست یافته است که نشان می‌دهد تقریباً ۷۰٪ از پلاک‌های واقعی توسط مدل شناسایی شده‌اند.



- precision دقت توانایی مدل را در جلوگیری از طبقه‌بندی پیکسل‌های غیرپلاک به عنوان پلاک اندازه‌گیری می‌کند. در این پروژه، مدل به دقت ۷۴ درصد دست یافته است، به این معنی که حدود ۷۵٪ از پیکسل‌هایی

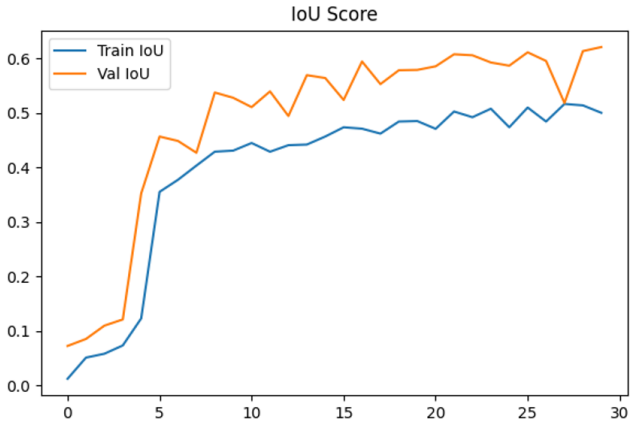
که مدل به عنوان پلاک طبقه‌بندی کرده، واقعاً پلاک بوده‌اند. این مقدار حاکی از آن است که مدل در تشخیص پلاک‌ها بسیار محتاط عمل کرده و موارد مثبت کاذب (False Positives) کمی تولید کرده است.



- امتیاز جاکارد (**IoU**): امتیاز جاکارد، مشابه ضریب دایس، همپوشانی بین ماسک پیش‌بینی شده و ماسک واقعی را می‌سنجد. فرمول آن به صورت زیر است:

$$IoU(P,G) = \frac{|P \cap G|}{|P \cup G|}$$

این معیار در پروژه‌هایی که به دقت همپوشانی هندسی اهمیت می‌دهند، بسیار کاربردی است. مدل به امتیاز جاکارد ۵۹ درصد دست یافته است. این مقدار، هرچند پایین‌تر از ضریب دایس است، اما همچنان نشان‌دهنده عملکرد مطلوب مدل در بخش‌بندی دقیق پلاک‌ها است.



۵.۹ بررسی نتایج تصویری

حال به بررسی نتایج تصویری می‌پردازیم.

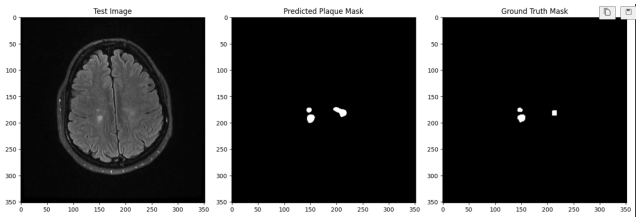


Figure ۹: مقایسه نتایج پیش‌بینی پلاک مدل و ماسک اصلی

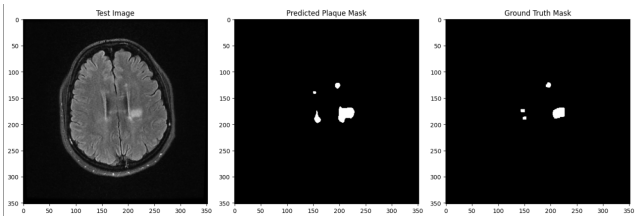


Figure ۱۰: مقایسه نتایج پیش‌بینی پلاک مدل و ماسک اصلی

۶.۹ نتایج مدل رو داده‌های تست

Metric	Value
Test Loss	0.2960
Test Dice Score	0.7040
Test IoU Score	0.5432
Test Precision	0.3775
Test Recall	0.3466
Test Accuracy	0.9985

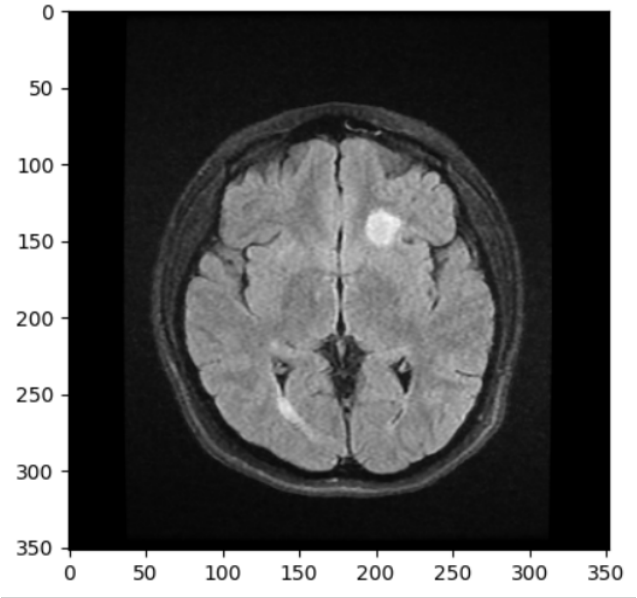


Figure ۱۱: عکس اصلی با ایندکس ۴۱

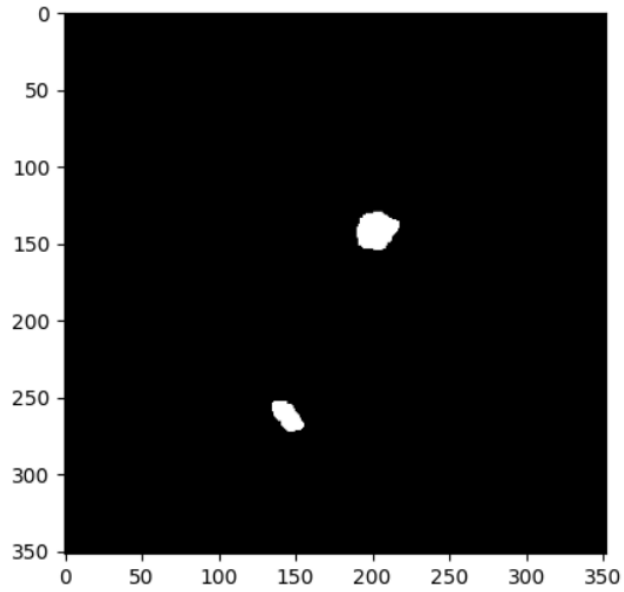


Figure ۱۲: ماسک حقیقی

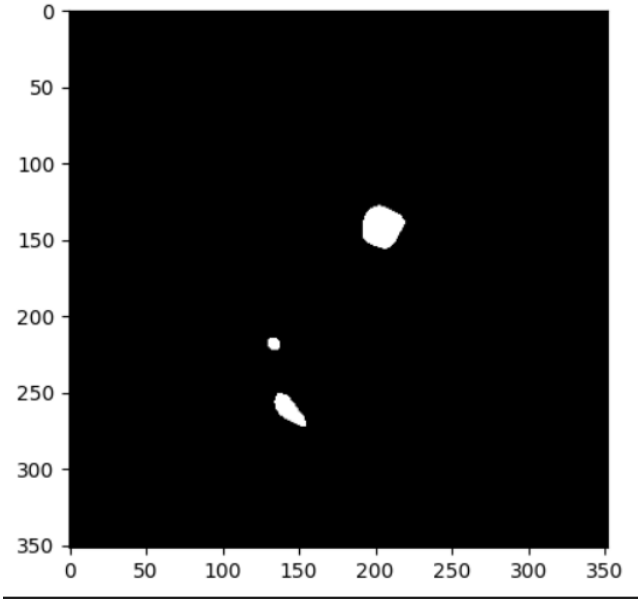


Figure ۱۳: ماسک پیش‌بینی شده

۱۰ نتیجه‌گیری

در این پروژه، ما با استفاده از تکنیک‌هایی مانند استفاده از خم‌های بزیه، تغییر مقیاس و چرخش و همچنین ترکیب واقع‌گرایانه پلاک‌های تولیدی با پس‌زمینه، موفق شدیم داده‌های جدیدی (حدودا ۱۵۰۰ داده جدید) تولید کنیم که نه تنها به مشکل کمبود داده در عرصه پزشکی پاسخ می‌دهد، بلکه تنوع این داده‌ها را نیز به طرز چشم‌گیری افزایش داد. همچنین استفاده از مدل U-net و

نتایج قابل قبول آن در متریک‌های مختلف نشان داد که این مدل، مدل خوبی برای مسائل پزشکی از جمله segmentation می‌باشد.